

Descrição do Projeto de Integração

Este projeto tem como objetivo central a integração e consolidação de três conjuntos de dados distintos, porém relacionados, que abrangem diferentes períodos temporais. O principal propósito é criar um **Data Warehouse modelado em Esquema Estrela (Star Schema)**, contendo Tabelas Fato e Dimensões, que sirva como um recurso robusto para análises aprofundadas, consultas complexas e geração de insights relevantes sobre o tema. Para atingir esse objetivo, os grupos deverão aplicar técnicas de ETL (Extração, Transformação e Carga) e ELT (Extração, Carga e Transformação), utilizando o ambiente Google Colab.

Recomenda-se que as bases de dados utilizadas sejam de anos consecutivos (por exemplo: 2022, 2023 e 2024), para facilitar comparações temporais e garantir uma maior coerência na análise dos dados ao longo do tempo.

Entregas do projeto

Os grupos devem entregar os seguintes itens. A entrega deve demonstrar **claramente o esforço coletivo**, detalhar **cada passo realizado** e conter **evidências do trabalho** (ex: prints, comentários no código, links, etc). O repositório no GitHub deve mostrar as contribuições **individuais de cada integrante**, com commits bem organizados e descritos.

Os grupos deverão entregar os seguintes itens:

1. **Apresentação Detalhada:** Uma apresentação que detalha o processo de integração dos dados. Esta apresentação deverá incluir, se possível, uma representação visual clara e concisa (um diagrama elaborado no Draw) das fontes de dados originais e do fluxo do processo de integração.
2. **Relatório Completo:**
 - **Descrição da Modelagem Dimensional (Esquema Estrela) e Dicionário de Dados:** Uma descrição da base de dados resultante, incluindo seus atributos, estrutura e metadados relevantes.
 - **Explicação Detalhada do Processo de Integração:** Um relato pormenorizado de cada etapa do processo de integração, desde a coleta dos dados até a sua consolidação final.
 - **Justificativa da Escolha da Base de Dados:** Uma argumentação clara e lógica das razões que levaram à escolha da base de dados específica para este projeto.
 - **Descrição dos Processos de Transformação Aplicados:** Uma descrição detalhada de todas as transformações aplicadas aos dados para garantir a sua qualidade e consistência.
 - **Comparativo entre ETL e ELT:** Uma análise comparativa entre os processos ETL e ELT utilizados na base de dados, destacando suas vantagens, desvantagens e adequação ao contexto do projeto.
 - **Apresentação de Três Análises e Insights:** A apresentação de três análises distintas realizadas com a base de dados, juntamente com os insights

significativos obtidos a partir dessas análises.

- **Reflexão sobre o Aprendizado:** Uma seção de reflexão sobre o aprendizado adquirido ao longo do processo de realização do projeto, incluindo desafios superados e lições aprendidas.

3. **Script do Pipeline de Dados:**

- **Notebook Collab ETL:** Um notebook Collab contendo o script completo do pipeline ETL utilizado no projeto, e o resultado do pipeline no banco de dados final escolhido.
- **Notebook Collab ELT:** Um notebook Collab contendo o script completo do pipeline ELT; todos os scripts de transformação de dados utilizados para transformação dos dados dentro do banco de dados escolhido + resultado do pipeline no banco de dados final escolhido.

4. **Repositório no Github:** Um **repositório público no GitHub** deve ser criado para centralizar **tudo o material do projeto**, incluindo:

- **Códigos e scripts utilizados** (ETL, ELT, transformações, consultas);
- **Documentação completa** (relatório, explicações, reflexões, etc.);
- **Notebooks em Colab**, divididos por tipo de processo (ETL e ELT);
- O repositório deve estar **bem estruturado**, e um README.md com instruções básicas e como rodar o projeto.
- Os **commits de cada integrante** devem estar **claros e rastreáveis**. É obrigatório:
 - i. **Evitar mensagens genéricas** como “ajuste final”, “update”, “teste”;
 - ii. Utilizar mensagens **descritivas**, como por exemplo: “Criação do pipeline ETL para a base de 2020” ou “Normalização da coluna de datas na base de infrações”;
 - iii. Garantir que a **autoria de cada parte do projeto esteja visível**, valorizando a contribuição individual de todos os membros do grupo.

5. **Para a Apresentação Final:**

- **Slides da Apresentação:** Os slides devem ser **concisos, bem organizados e informativos**, destacando **tudo o esforço do grupo** no desenvolvimento do projeto. A apresentação deve:
 - i. Explicar **sobre o que é a base de dados** escolhida (contexto, fonte, conteúdo e relevância);
 - ii. Apresentar as **tecnologias utilizadas** e justificar **por que foram escolhidas**;
 - iii. Mostrar os **processos feitos até chegar à base final**, explicando:
 - 1. O que foi feito;
 - 2. **Por que foi feito**;
 - 3. Qual era o **objetivo com os processos de ETL e ELT**;
 - iv. Destacar **diferenças percebidas nos dados** ao longo do tempo (por exemplo, se houve adição de novas colunas, remoção de um ano para o outro);
 - v. Comparar os processos de **ETL e ELT**, explicando as diferenças e **quais foram aplicados em cada etapa do projeto**;
 - vi. Evidenciar, sempre que possível, **resultados intermediários** para mostrar a evolução do trabalho;
 - vii. Reforçar o papel de cada integrante ao longo do projeto.
- **Apresentação:** A professora poderá escolher um ou mais membros para

apresentar. A nota da apresentação será a nota de todo o grupo;

- i. **Todos devem estar presentes no dia da apresentação. Ausências devem ser avisadas com antecedência** para possível remarcação.

Composição da nota

- A nota é composta pela nota da apresentação, documento e repositório. A apresentação **tem um peso maior**, que é **definido pela professora**.
- O projeto tem peso de **85% da segunda nota da disciplina**

Temas Propostos

1. **Acidentes de trânsito (PRF):** A base de dados de acidentes da Polícia Rodoviária Federal (PRF) consolida informações de todos os sinistros ocorridos na malha rodoviária federal desde 2007. Ela é alimentada pelo Boletim de Acidente de Trânsito (BAT) e detalha o local, a severidade, o tipo de via, fatores climáticos, causas, veículos e características dos envolvidos. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>
2. **Doses aplicadas pelo Programa de Nacional de Imunizações (PNI):** Dados sobre as doses aplicadas pelo Programa Nacional de Imunizações, disponíveis em https://opendatasus.saude.gov.br/organization/ministerio-da-saude?q=Doses+aplicadas+pelo+Programa+de+Nacional+de+Imuniza%C3%A7%C3%B5es+%28PNI%29&sort=score+desc%2C+metadata_modified+desc
3. **Imposto sobre Transmissão de Bens Imóveis (ITBI):** O Imposto sobre a Transmissão de Bens Imóveis (ITBI), pago na compra/venda de imóveis Os dados contém a relação de transações imobiliárias com recolhimento de ITBI, contendo as características dos imóveis e informações sobre as operações. Disponíveis e https://dados.recife.pe.gov.br/pt_PT/dataset/impuesto-sobre-transmissao-de-bens-imoveis-itbi
4. **Acidentes de Trânsito com Vítima (2014 - 2016):** Dados dos acidentes com vítimas do trânsito de Recife. Disponíveis em:
 - a. 2014: <https://dados.recife.pe.gov.br/dataset/acidentes-de-transito-com-vitimas-2014>
 - b. 2015: <https://dados.recife.pe.gov.br/dataset/acidentes-de-transito-com-vitimas-2015>
 - c. 2016: <https://dados.recife.pe.gov.br/dataset/acidentes-de-transito-c-vitimas-2016>
5. **Cadastro Nacional de Reclamações Fundamentadas (PROCONS - Sindec):** O Sistema Nacional de Informações de Defesa do Consumidor – Sindec é um sistema informatizado que integra processos e procedimentos, relativos ao atendimento aos consumidores nos Procons, visando proporcionar um instrumento de gestão adequado ao dinamismo que é típico de seus setores de atendimento. Disponível em: <https://dados.mj.gov.br/dataset/cadastro-nacional-de-reclamacoes-fundamentadas-procons-sindec>
6. **Registro de Ocupação Hospitalar COVID-19:** Registro das internações por meio do Sistema ESUS Notifica-Módulo Internações SUS. Disponível em: <https://dadosabertos.saude.gov.br/dataset/registro-de-ocupacao-hospitalar-covid-19>

7. **Hospitais e Leitos:** Disponibilização de dados gerais dos estabelecimentos hospitalares, leitos gerais e complementares, bem como informações de contato com os estabelecimentos como endereço, telefone e e-mail. Disponível em: <https://dadosabertos.saude.gov.br/dataset/hospitais-e-leitos>
8. **Banco de Preços em Saúde - BPS:** O Banco de Preço em Saúde - BPS é um sistema de registro de informações de compras públicas e privadas de medicamentos e dispositivos médicos. Sua principal finalidade é possibilitar o uso de informações de compras públicas e privadas de medicamentos e dispositivos médicos, a fim de subsidiar a compra pública mais eficiente no setor saúde, pelos entes federados e instituições de saúde. Disponível em: <https://dadosabertos.saude.gov.br/dataset/bps>
9. **SAMP - Sistema de Acompanhamento de Informações de Mercado para Regulação Econômica:** Informações do mercado de energia elétrica, declaradas pelas concessionárias e permissionárias de distribuição, conforme critérios definidos na Resolução Normativa Aneel N° 1.003, DE 1º DE FEVEREIRO DE 2022. Disponível em: <https://dadosabertos.aneel.gov.br/dataset/samp>
10. **Indicadores que avaliam a satisfação do passageiro com os processos e serviços aeroportuários a ele oferecidos, coletados nos aeroportos durante a pesquisa (20 aeroportos principais):** Conjunto de dados provenientes da Pesquisa de Satisfação do Passageiro realizada pela Secretaria Nacional de Aviação Civil (SAC). Disponível em: <https://dados.transportes.gov.br/gl/dataset/pesquisa-de-satisfacao-do-passageiro-em-aeroportos>
11. **Recursos Transferidos:** Base de dados que retrata as Transferências de Recursos Públicos Federais. Em termos simples, ela funciona como um grande "extrato bancário" que registra todo o dinheiro que o Governo Federal retira dos seus cofres e envia para estados, municípios, empresas, ONGs ou diretamente para os cidadãos. Disponível em: <https://portal.datatransparencia.gov.br/download-de-dados/transferencias>
12. **Programa Universidade para Todos (PROUNI):** Dados referentes ao detalhamento quantitativo das bolsas concedidas por ano, segmentadas por região, unidade federativa e município, instituição de educação superior, nome do curso, modalidade de ensino (presencial ou a distância – EAD), turno e tipo de bolsa. Disponível em: <https://dadosabertos.mec.gov.br/prouni>
13. **Multas aplicadas pela Polícia Rodoviária Federal (PRF):** O catálogo de Dados Abertos de Multas da PRF disponibiliza informações públicas, detalhadas e sem restrições sobre autos de infração lavrados nas rodovias federais brasileiras. Ele compila o volume estatístico de infrações e as características das ocorrências de trânsito, respeitando o sigilo de dados pessoais. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>